

Modelowanie ryzyka kredytowego w banku

Franciszek Kotowski, 223318

Lista zmiennych w modelu

- Y – Default (0 = Spłacony, 1 = Problemy ze spłatą)
- X1 – Kwota_Kredytu (Wysokość udzielonego kredytu)
- X2 – Dlugosc_Kredytu (Czas trwania w miesiącach)
- X3 – Rata_Kredytu (Miesięczna rata)
- X4 – Wiek (Wiek w momencie brania kredytu)
- X5 – Plec (1 = Kobieta, 0 = Mężczyzna)
- X6 – Bezrobocie (Stopa bezrobocia w regionie zamieszkania)
- X7 – Przestepczosc (Liczba przestępstw w regionie)
- X8 – Srednia_Pensja (Średnie zarobki w regionie)
- X9 – Urbanizacja (Liczba mieszkańców gminy – czy miasto, czy wieś)
- X10 – Staz_Klienta (Ile miesięcy ma konto przed wzięciem kredytu)
- X11 – Czestosc_Wyciagu (1 = Miesięcznie, 0 = Inne)
- X12 – Posiada_Karte (Czy posiada kartę płatniczą)
- X13 – Posiada_Karte_Gold (Czy jest to karta prestiżowa Gold)
- X14 – Liczba_Zleceń (Liczba aktywnych stałych zleceń na koncie)
- X15 – Suma_Zleceń (Łączna kwota miesięcznych stałych opłat)
- X16 – Oplaca_Ubezpieczenie (Czy ma stałe zlecenie na ubezpieczenie)
- X17 – Oplaca_Mieszkanie (Czy płaci czynsz/media przez SIPO)
- X18 – Srednie_Saldo (Średni stan konta od początku)
- X19 – Min_Saldo (Najniższy stan konta w historii)
- X20 – Max_Saldo (Najwyższy stan konta w historii)
- X21 – Odchylenie_Salda (Stabilność finansowa)
- X22 – Suma_Wplywow (Łączna suma wpłat na konto)
- X23 – Suma_Wydatkow (Łączna suma wydatków)
- X24 – Liczba_Transakcji (Jak często używa konta)
- X25 – Liczba_Kar (Ile razy bank naliczył karne odsetki za brak środków)
- X26 – Srednie_Saldo_3M (Średnie saldo z ostatnich 90 dni)

X27 – Min_Saldo_3M (Czy wpadł w debet tuż przed kredytem)

X28 – Wpływy_3M (Dochód z ostatnich 3 miesięcy)

X29 – Wskaznik_DTI (Rata kredytu podzielona przez miesięczny dochód)

X30 – Wskaznik_Oszczedzania (Stosunek wydatków do wpływów)

Model



Metadane wykonano.

Biblioteka: AAEM
Źródło danych: FINAL_TABLE
Rola: Surowe

Rola	Poziom	Liczebność
Id.	Przedziałowa	1
Wejście	Binarna	6
Wejście	Przedziałowa	21
Wejście	Nominalna	3
Zmienna celu	Binarna	1

Eksploruj - AAEM.FINAL_TABLE

Plik Widok Działania Okno

Właściwości

Wartość

Wiersze

682

Kolumny

32

Biblioteka

AAEM

Element

FINAL_TABLE

Typ

DATA

Metoda próbkowania

Góra

Wielkość pobrania

Domyślna

Pobrane wiersze

682

Ziarno losowe

12345

Zastosuj


Wyfres...

Statystyki próby


Nr obs	Nazwa z...	Etykieta	Typ	Procent b...	Minimum	Maksimum	Średnia
1	Bezrobocie	VAR		0	0.29	7.34	2.949267
2	Czestosc_...	VAR		0	0	1	0.819648
3	Default	VAR		0	0	1	0.111437
4	Dlugosc_Kr...	VAR		0	12	60	36.49267
5	Kwota_Kre	VAR		0	4980	590820	15410.2
6	Liczba_Kar	VAR		0	0	10	0.118768
7	Liczba_Tra	VAR		0	2	218	80.19648
8	Liczba_Zlec	VAR		0	1	5	2.218475
9	Max_Saldo	VAR		0	10100	193909.9	89016.24
10	Min_Saldo	VAR		0	-17030.4	20574	656.1516
11	Min_Saldo	VAR		0	-17030.4	64270.5	23539.12
12	Odchylenie	VAR		0	4462.71	35436.03	18355.48
13	Oplaca_Mie	VAR		0	0	1	0.646628
14	Oplaca_Ub	VAR		0	0	1	0.167155
15	Plec	VAR		0	0	1	0.510264
16	Posiada_K...	VAR		0	0	1	0.249267
17	Posiada_K...	VAR		0	0	1	0.02346
18	Przestepcz	VAR		0	818	85677	14062.36
19	Rata_Kredytu	VAR		0	304	9910	4190.664



AAEM.FINAL_TABLE

Nr obs	loan_id	Default	Kwota_Kr...	Dlugosc_...	Rata_Kre...	Wiek	Plec	Bezrobocie	Przestep...	Średnia	Urbanizacja	Staz_Klie	Czestosc	Posiada_...	Posiada_...	Liczba_Zi	Suma_Zi	Oplac
1	4959	0	80952	24	3373	48.51472	0	0.29	85677	12541	1204953	10.29605	1	0	0	2	10638.7	
2	4961	1	30276	12	2523	56.82957	1	1.51	2299	9104	103347	12.76316	1	0	0	1	2523.2	
3	4962	0	30276	12	2523	35.43874	0	4.09	5623	9893	228848	16.38158	1	0	0	4	10614.2	
4	4967	1	318480	60	5308	46.28611	0	2.65	1563	8547	70546	13.88158	1	0	0	4	10305.5	
5	4968	0	110736	48	2307	57.79077	1	3.13	999	8402	51428	8.355263	0	0	0	4	9666.8	
6	4973	0	165960	24	6915	51.83573	1	1.12	1874	8427	93931	18.45395	1	0	0	3	13753	
7	4986	0	102876	12	8573	55.1102	0	4.75	18782	10673	323870	15.19737	1	1	0	5	12438	
8	4988	1	265320	36	7370	30.43395	0	2.79	2166	8254	105606	20.92105	1	0	0	1	7370.2	
9	4989	0	352704	48	7348	48.42984	1	1.51	2299	9104	103347	16.875	1	1	0	1	7348	
10	4990	0	162576	36	4516	44.18891	0	3.33	5796	9198	159617	13.75	1	1	0	3	7664	
11	4996	0	88440	12	7370	51.35113	1	6.49	6949	8317	128118	5.888158	0	1	0	1	7370.2	
12	5002	0	104808	12	8734	54.91581	0	3.51	2247	8512	125932	6.116421	1	0	0	5	17342	
13	5005	0	27456	12	2288	29.77687	0	5.93	4980	8678	161227	7.927632	0	0	0	4	6985.3	
14	5015	0	109344	12	9112	54.02875	1	6.63	9878	10177	285387	16.57895	1	1	0	2	18040	
15	5027	0	160920	36	4470	27.42231	0	7.08	2653	8965	85852	11.80921	1	1	0	2	9682.5	
16	5032	0	123696	48	2577	54.34086	0	4.69	2854	8772	124605	11.05263	1	0	0	3	8504	
17	5034	0	112752	36	3132	41.91102	1	5.93	4980	8678	161227	22.17105	1	1	0	2	6935	
18	5036	0	91248	48	1901	25.40178	1	1.42	6604	10045	177686	19.04605	1	0	0	1	1901	




Drzewo 1 (Maximal Tree)






Drzewo 2




Właściwość	Wartość
Reguła podziału	
- Kryterium przedziałowej zm	ProbF
- Kryterium nominalnej zm	ProbChisq
- Kryterium porządkowej zm	Entropia
- Poziom istotności	0.2
- Braki danych	Użyj w wyszukiwaniu
- Używaj jednorazowo	Nie
- Maksymalne rozgałęzienie	2
- Maksymalna głębia	6
- Minimalna wielkość zmiennej	5
Węzeł	
- Wielkość liścia	5
- Liczba reguł	5
- Liczba reguł zastępczych	0
- Wielkość podziału	.
Poszukiwanie podziału	
- Użyj decyzji	Nie
- Użyj prawdopodobieństw a	Nie
- Wyczerpujące	5000
- Próba węzła	20000
Poddrzewo	
- Metoda	Ocena
- Liczba liści	1
- Miara oceny	Decyzja
- Ułamek ocen	0.25

Drzewo 3




Właściwość	Wartość
Reguła podziału	
Kryterium przedziałowej zm.	ProbF
Kryterium nominalnej zm.	ProbChisq
Kryterium porządkowej zm.	Entropia
Poziom istotności	0.2
Braki danych	Użyj w wyszukiwaniu
Używaj jednorazowo	Nie
Maksymalne rozgałęzienie	2
Maksymalna głębia	6
Minimalna wielkość zmiennej	5
Węzeł	
Wielkość liścia	5
Liczba reguł	5
Liczba reguł zastępczych	0
Wielkość podziału	.
Poszukiwanie podziału	
Użyj decyzji	Nie
Użyj prawdopodobieństw a	Nie
Wyczerpujące	5000
Próba węzła	20000
Poddrzewo	
Metoda	Ocena
Liczba liści	1
Miara oceny	Średni błąd kwadratowy
Ułamek ocen	0.25

Drzewo 4



Reguła podziału	
Kryterium przedziałowej zm	ProbF
Kryterium nominalnej zm	Entropia
Kryterium porządkowej zm	Wsp. Giniego
Poziom istotności	0.2
Braki danych	Użyj w wyszukiwaniu
Używaj jednorazowo	Nie
Maksymalne rozgałęzienie	2
Maksymalna głębia	6
Minimalna wielkość zmiennej	5
Węzeł	
Wielkość liścia	5
Liczba reguł	5
Liczba reguł zastępczych	0
Wielkość podziału	.
Poszukiwanie podziału	
Użyj decyzji	Nie
Użyj prawdopodobieństw a	Nie
Wyczerpujące	5000
Próba węzła	20000
Poddrzewo	
Metoda	Ocena
Liczba liści	1
Miara oceny	Decyzja
Ułamek ocen	0.25

Drzewo 5



Reguła podziału	
Kryterium przedziałowej zm	ProbF
Kryterium nominalnej zm	Entropia
Kryterium porządkowej zm	Entropia
Poziom istotności	0.2
Braki danych	Użyj w wyszukiwaniu
Używaj jednorazowo	Nie
Maksymalne rozgałęzienie	2
Maksymalna głębia	6
Minimalna wielkość zmiennej	5
Węzeł	
Wielkość liścia	5
Liczba reguł	5
Liczba reguł zastępczych	0
Wielkość podziału	.
Poszukiwanie podziału	
Użyj decyzji	Nie
Użyj prawdopodobieństw a	Nie
Wyczerpujące	5000
Próba węzła	20000
Poddzweto	
Metoda	Ocena
Liczba liści	1
Miara oceny	Decyzja

Macierz klasyfikacji

Tabela klasyfikacji zdarzeń								
Wybór modelu w zależności od Walidacja: Odsetek błędnych klasyfikacji (_VMISC_)								
Węzeł modelu	Opis modelu	Rola danych	Zmienna celu	Etykieta zmiennej celu	Fałszywie ujemne	Prawdziwie ujemne	Fałszywie dodatnie	Prawdziwie dodatnie
Tree	Drzewo decyzyjne	TRAIN	Default		17	415	8	35
Tree	Drzewo decyzyjne	VALIDATE	Default		9	180	3	15
Tree2	Drzewo decyzyjne (2)	TRAIN	Default		33	420	3	19
Tree2	Drzewo decyzyjne (2)	VALIDATE	Default		10	183	.	14
Tree3	Drzewo decyzyjne (3)	TRAIN	Default		15	412	11	37
Tree3	Drzewo decyzyjne (3)	VALIDATE	Default		8	180	3	16
Tree4	Drzewo decyzyjne (4)	TRAIN	Default		34	423	0	18
Tree4	Drzewo decyzyjne (4)	VALIDATE	Default		13	183	0	11
Tree5	Drzewo decyzyjne (5)	TRAIN	Default		34	423	0	18
Tree5	Drzewo decyzyjne (5)	VALIDATE	Default		13	183	0	11

Porównanie modeli


Statystyki dopasowania							
Wybór modelu w zależności od Walidacja: Odsetek błędnych klasyfikacji (_VMISC_)							
Wybrany model	Węzeł modelu	Opis modelu	Walidacja: Odsetek błędnych klasyfikacji	Uczenie: Przeciętny błąd kwadratowy	Uczenie: Odsetek błędnych klasyfikacji	Walidacja: Przeciętny błąd kwadratowy	
Y	Tree2	Drzewo decyzyjne (2)	0.048309	0.058395	0.075789	0.052938	
	Tree3	Drzewo decyzyjne (3)	0.053140	0.044176	0.054737	0.046451	
	Tree	Drzewo decyzyjne	0.057971	0.041298	0.052632	0.052538	
	Tree4	Drzewo decyzyjne (4)	0.062802	0.052315	0.071579	0.058828	
	Tree5	Drzewo decyzyjne (5)	0.062802	0.052315	0.071579	0.058828	

Drzewo 2 jest najlepsze, ponieważ ma najniższy błąd klasyfikacji na zbiorze walidacyjnym.

Statystyki dopasowania

Tabela statystyk dopasowania					
Zmienna celu: Default					
Rola danych=Train					
Statystyki	Tree2	Tree3	Tree	Tree4	Tree5
Uczenie: Obcięcie prawdopodobieństwa klasowego dwuczynnikowego Kołmogorowa-Smirnowa	0.464	0.108	0.134	0.145	0.145
Uczenie: Statystyka Kołmogorowa-Smirnowa	0.573	0.696	0.701	0.687	0.687
Uczenie: Przeciętny błąd kwadratowy	0.058	0.044	0.041	0.052	0.052
Uczenie: Indeks ROC	0.793	0.911	0.929	0.929	0.929
Uczenie: Skumulowana odpowiedź procentowa otrzymana	59.753	71.154	71.154	59.856	59.856
Uczenie: Odpowiedź procentowa otrzymana	21.429	28.709	25.000	20.192	20.192
Kryterium wyboru: Walidacja: Odsetek błędnych klasyfikacji	0.048	0.053	0.058	0.063	0.063
Uczenie: Łączne stopnie swobody	475.000	475.000	475.000	475.000	475.000
Uczenie: Podzielnik ASE	950.000	950.000	950.000	950.000	950.000
Uczenie: Zysk	491.303	604.127	604.127	492.323	492.323
Uczenie: Współczynnik Giniego	0.586	0.822	0.857	0.858	0.858
Uczenie: Klasowa dwuczynnikowa statystyka Kołmogorowa-Smirnowa	0.558	0.688	0.699	0.676	0.676
Uczenie: Odcięcie prawdopodobieństwa Kołmogorowa-Smirnowa	0.050	0.080	0.080	0.080	0.080
Uczenie: Skumulowany lift	5.913	7.041	7.041	5.923	5.923
Uczenie: Lift	4.241	5.682	4.948	3.996	3.996
Uczenie: Maksymalny błąd bezwzględny	0.953	0.986	0.993	0.922	0.922
Uczenie: Odsetek błędnych klasyfikacji	0.076	0.055	0.053	0.072	0.072
Uczenie: Suma liczebności	475.000	475.000	475.000	475.000	475.000
Uczenie: Pierwiastek ze średniego błędu kwadratowego	0.242	0.210	0.203	0.229	0.229
Uczenie: Skumulowana odpowiedź procentowa	64.732	77.083	77.083	64.844	64.844
Uczenie: Odpowiedź procentowa	46.429	62.202	54.167	43.750	43.750
Uczenie: Suma błędów kwadratowych	55.475	41.967	39.234	49.700	49.700
Rola danych=Valid					
Statystyki	Tree2	Tree3	Tree	Tree4	Tree5
Walidacja: Statystyka Kołmogorowa-Smirnowa	0.607	0.650	0.650	0.613	0.613
Walidacja: Przeciętny błąd kwadratowy	0.053	0.046	0.053	0.059	0.059
Walidacja: Indeks ROC	0.821	0.897	0.879	0.873	0.873
Walidacja: Obcięcie prawdopodobieństwa klasowego dwuczynnikowego Kołmogorowa-Smirnowa	0.732	0.571	0.571	0.712	0.712
Walidacja: Skumulowana odpowiedź procentowa otrzymana	62.821	67.500	67.500	52.244	52.244
Walidacja: Odpowiedź procentowa otrzymana	16.987	21.667	28.214	6.410	6.410
Walidacja: Podzielnik VASE	414.000	414.000	414.000	414.000	414.000
Walidacja: Zysk	519.231	565.357	565.357	414.973	414.973
Walidacja: Współczynnik Giniego	0.642	0.795	0.758	0.745	0.745
Walidacja: Klasowa dwuczynnikowa statystyka Kołmogorowa-Smirnowa	0.596	0.649	0.649	0.606	0.606
Walidacja: Odcięcie prawdopodobieństwa Kołmogorowa-Smirnowa	0.050	0.150	0.150	0.080	0.080
Walidacja: Skumulowany lift	6.192	6.654	6.654	5.150	5.150
Walidacja: Lift	3.516	4.485	5.840	1.327	1.327
Walidacja: Maksymalny błąd bezwzględny	0.953	0.986	1.000	1.000	1.000
Walidacja: Odsetek błędnych klasyfikacji	0.048	0.053	0.058	0.063	0.063
Walidacja: Suma liczebności	207.000	207.000	207.000	207.000	207.000
Walidacja: Pierwiastek ze średniego błędu kwadratowego	0.230	0.216	0.229	0.243	0.243
Walidacja: Skumulowana odpowiedź procentowa	71.795	77.143	77.143	59.707	59.707
Walidacja: Odpowiedź procentowa	40.769	52.000	67.714	15.385	15.385
Walidacja: Suma błędów kwadratowych	21.916	19.231	21.751	24.355	24.355

ROC



Kod

```
libname bank '/home/u64365845/projekt';
```

```
data loan_base;
```

```
set bank.loan;
```

```
if status in ('A', 'C') then Default = 0;
```

```
else if status in ('B', 'D') then Default = 1;
```

```
Kwota_Kredytu = amount;
```

```
Dlugosc_Kredytu = duration;
```

```
Rata_Kredytu = payments;
```

```
rename date = Data_Kredytu;
```

```
run;
```

```
proc sql;
```

```
create table client_geo as
```

```
select
```

```
c.client_id,
```

```
c.district_id,
```

```
1900 + input(substr(put(c.birth_number,z6.), 1, 2), 2.) as Rok_Urodzenia,
```

```
case when input(substr(put(c.birth_number,z6.), 3, 2), 2.) > 50 then 1 else 0 end as Plec,
```

```
d.A12 as Bezrobocie,
```

```
d.A15 as Przestepczosc,
```

```
d.A11 as Srednia_Pensja,
```

```
d.A4 as Urbanizacja
```

```
from bank.client c
```

```
left join bank.district d
```

```
on c.district_id = d.A1;
```

```
quit;
```

```
data client_final;
```

```
set client_geo;
```

```
Data_Urodzenia = mdy(7, 1, Rok_Urodzenia);
```

```
drop Rok_Urodzenia;
```

```
run;
```

```
proc sql;  
create table trans_history as  
select  
t.*,  
l.loan_id,  
l.Data_Kredytu  
from  
bank.trans t,  
loan_base l  
where  
t.account_id = l.account_id  
and t.date < l.Data_Kredytu;  
quit;
```

```
proc sql;  
create table feats_trans as  
select  
loan_id,
```

```
mean(balance) as Srednie_Saldo,  
min(balance) as Min_Saldo,  
max(balance) as Max_Saldo,  
std(balance) as Odchylenie_Salda,  
sum(case when type='PRIJEM' then amount else 0 end) as Suma_Wplywow,  
sum(case when type='VYDAJ' then amount else 0 end) as Suma_Wydatkow,  
count(*) as Liczba_Transakcji,  
sum(case when k_symbol = 'SANKC. UROK' then 1 else 0 end) as Liczba_Kar,
```

```
mean(case when (Data_Kredytu - date) <= 90 then balance else . end) as  
Srednie_Saldo_3M,  
min(case when (Data_Kredytu - date) <= 90 then balance else . end) as Min_Saldo_3M,  
sum(case when (Data_Kredytu - date) <= 90 and type='PRIJEM' then amount else 0 end)  
as Wplywy_3M
```

```
from trans_history  
group by loan_id;  
quit;
```

```
proc sql;
```

```

create table feats_products as
select
a.account_id,

a.date as Data_Zalozenia,
case when a.frequency = 'POPLATEK MESICNE' then 1 else 0 end as Czestosc_Wyciagu,

max(case when ca.card_id is not null then 1 else 0 end) as Posiada_Karte,
max(case when ca.type = 'gold' then 1 else 0 end) as Posiada_Karte_Gold,

count(distinct o.order_id) as Liczba_Zleceń,
sum(o.amount) as Suma_Zleceń,
sum(case when o.k_symbol = 'POJISTNE' then 1 else 0 end) as Oplaca_Ubezpieczenie,
sum(case when o.k_symbol = 'SIPO' then 1 else 0 end) as Oplaca_Mieszkanie

from
bank.account a
left join bank.disp d on a.account_id = d.account_id and d.type = 'OWNER'
left join bank.card ca on d.disp_id = ca.disp_id
left join bank.order o on a.account_id = o.account_id
group by a.account_id, a.date, a.frequency;
quit;

proc sql;
create table bank.Final_Table as
select
l.loan_id,
l.Default,

l.Kwota_Kredytu,
l.Dlugosc_Kredytu,
l.Rata_Kredytu,

(l.Data_Kredytu - c.Data_Urodzenia) / 365.25 as Wiek,
c.Plec, c.Bezrobocie, c.Przestepczosc, c.Srednia_Pensja, c.Urbanizacja,

(l.Data_Kredytu - p.Data_Zalozenia) / 30.4 as Staz_Klienta,
p.Czestosc_Wyciagu,
coalesce(p.Posiada_Karte, 0) as Posiada_Karte,
coalesce(p.Posiada_Karte_Gold, 0) as Posiada_Karte_Gold,

```

```

coalesce(p.Liczba_Zleceń, 0) as Liczba_Zleceń,
coalesce(p.Suma_Zleceń, 0) as Suma_Zleceń,
coalesce(p.Oplaca_Ubezpieczenie, 0) as Oplaca_Ubezpieczenie,
coalesce(p.Oplaca_Mieszkanie, 0) as Oplaca_Mieszkanie,

coalesce(t.Srednie_Saldo, 0) as Srednie_Saldo,
coalesce(t.Min_Saldo, 0) as Min_Saldo,
coalesce(t.Max_Saldo, 0) as Max_Saldo,
coalesce(t.Odchylenie_Salda, 0) as Odchylenie_Salda,
coalesce(t.Suma_Wplywow, 0) as Suma_Wplywow,
coalesce(t.Suma_Wydatkow, 0) as Suma_Wydatkow,
coalesce(t.Liczba_Transakcji, 0) as Liczba_Transakcji,
coalesce(t.Liczba_Kar, 0) as Liczba_Kar,
coalesce(t.Srednie_Saldo_3M, 0) as Srednie_Saldo_3M,
coalesce(t.Min_Saldo_3M, 0) as Min_Saldo_3M,
coalesce(t.Wplywy_3M, 0) as Wplywy_3M,

l.payments / ( ( t.Wplywy_3M / 3 ) + 1 ) as Wskaznik_DTI,
(coalesce(t.Suma_Wydatkow,0) + 1) / (coalesce(t.Suma_Wplywow,0) + 1) as
Wskaznik_Oszczedzania

from
loan_base l
left join bank_disp d on l.account_id = d.account_id and d.type = 'OWNER'
left join client_final c on d.client_id = c.client_id
left join feats_products p on l.account_id = p.account_id
left join feats_trans t on l.loan_id = t.loan_id;
quit;

proc contents data=bank.Final_Table; run;

```